

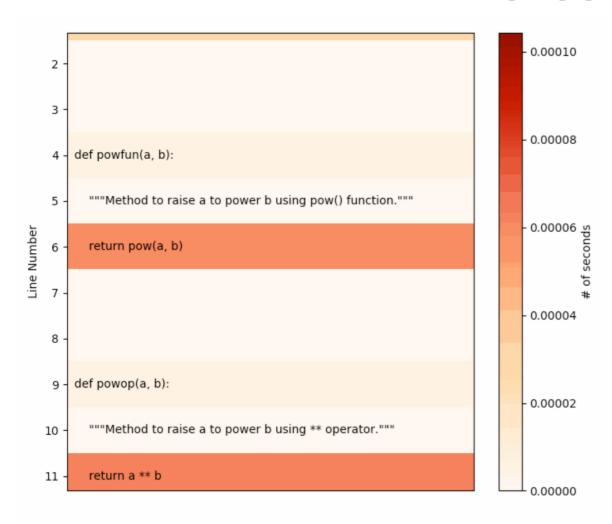
SELEZNEV ARTEM SENIOR DE @ SBER

HEARTREATE

```
27 1
                          def merge_sort(m):
28
29
                              Return a sorted copy of m
                              Uses the recursive merge sort algorithm
30
31
32
33 75001
                              if len(m) - 1:
34 37500
                                  return m
35 37501
                              middle = len(m) // 2
36 37501
                              left = m[:middle]
                              right = m[middle:]
37 37501
                              return merge(
38 37501
39 37501
                                   merge_sort(left), merge_sort(right)
40
41
42 1
                          def merge(left, right):
43 37498
                              result = []
                              left_idx, right_idx = 0, 0
44 37498
                              while left_idx = len(left) and right_idx = len(right):
45 518646
                                  if left[left_idx] = right[right_idx]:
46 481149
                                      result_append(left[left_idx])
47 237261
48 237261
                                      left_idx == 1
                                  else:
                                      result append(right[right_idx])
50 243887
                                      right_idx == 1
51 243887
52 37497
                              if left_idx = len(left):
53 16843
                                  result extend(left[left_idx:])
54 37497
                              if right_idx = len(right):
                                  result extend(right[right_idx:])
55 20654
56 37497
                              return result
```

https://github.com/alexmojaki/heartrate

PYHEAT

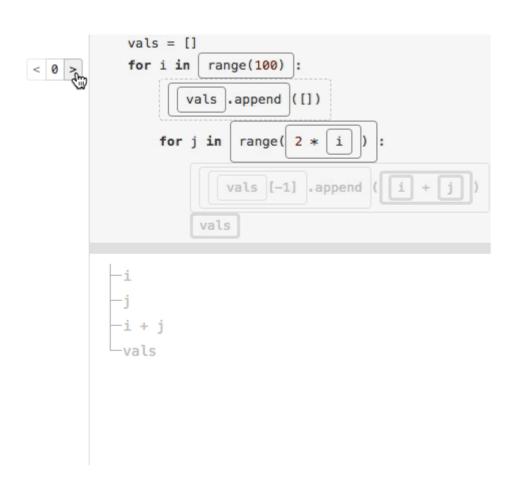


https://github.com/csurfer/pyheat

Scroll

10.82

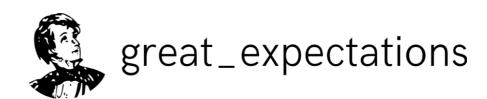
BIRDSEYE



https://github.com/alexmojaki/birdseye

НА СЕГОДНЯ

• Фиксация данных для DS pipeline



НА СЕГОДНЯ

• Фиксация данных для DS pipeline

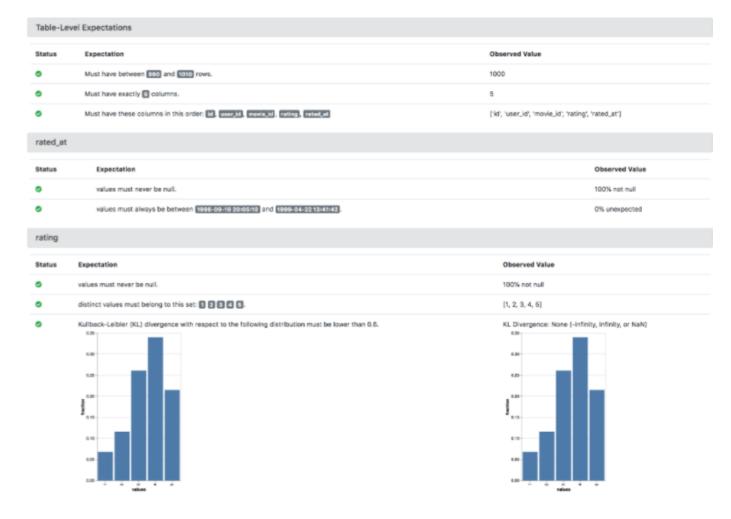
GREAT EXPECTATIONS



GE

 Сохранение и документирование статистики

Test | СI процесс



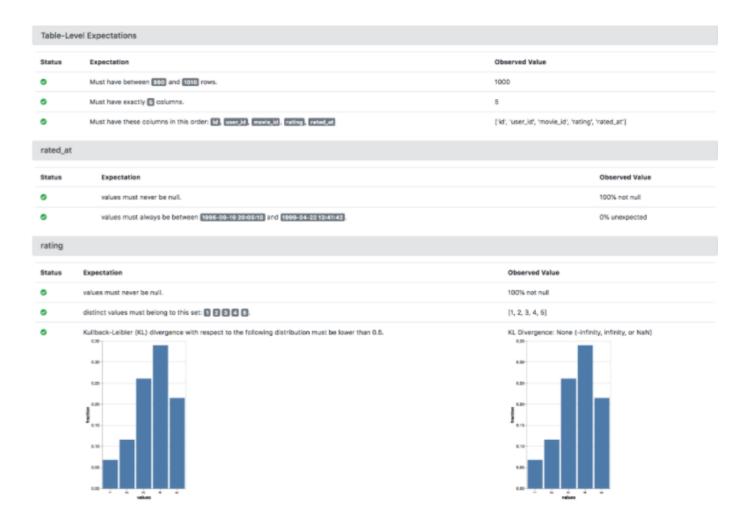
https://greatexpectations.io/

GE

• Документированные

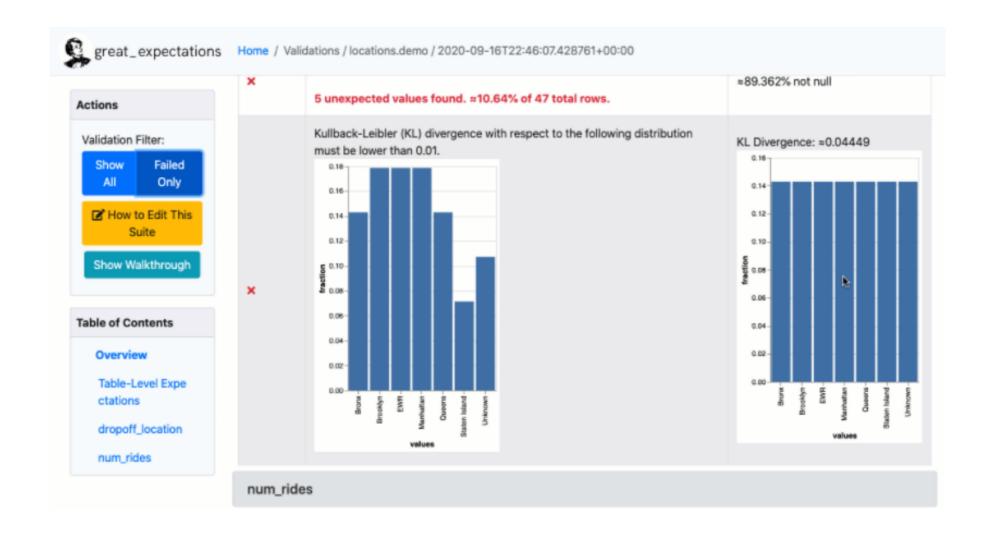
• Тестированные

• Стабильные



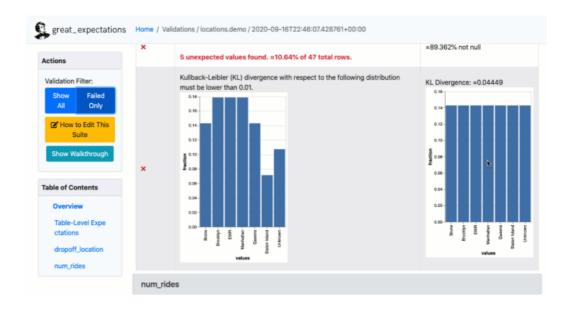
https://greatexpectations.io/

GE ACTION



GE ACTION

https://github.com/great-expectations/great_expectations_action



GE JUPYTER NOTEBOOK

FEATURE PROBLEM







_	user_id	dt	feature_1	feature_n
	777	2020-12-07 00:00:00	88.77	29.01



user_id	dt	feature_1	feature_n
777	2020-12-07 00:00:00	88.77	29.01

- SQL / Spark
- Python
- Scala



 user_id	dt	feature_1	feature_n
777	2020-12-07 00:00:00	88.77	29.01





user_id		dt	feature_1 feature_ı	
	777	2020-12-07 00:00:00	88.77	29.01

user_id	promo_id	dt	feature_1	feature_n
777	AFP99BC	2020-12-07 00:00:00	1	shop





user_id	ser_id dt		feature_n
777	2020-12-07 00:00:00	88.77	29.01



Python

Scala

user_id	promo_id	dt	feature_1	feature_n
777	AFP99BC	2020-12-07 00:00:00	1	shop





user_id	dt	feature_1	feature_n
777	2020-12-07 00:00:00	88.77	29.01

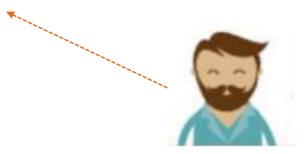




user_id	promo_id	dt	feature_1	feature_n
777	AFP99BC	2020-12-07 00:00:00	1	shop



		and the second second		
user_id	dt	feature_1	feature_n	
777	2020-12-07 00:00:00	88.77	29.01	- nord



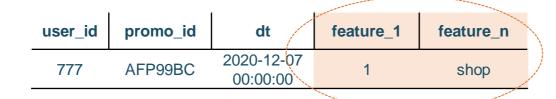


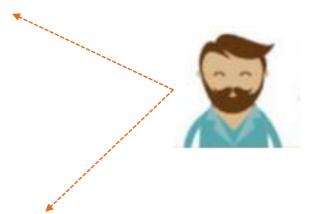
user_id	promo_id	dt	feature_1	feature_n
777	AFP99BC	2020-12-07 00:00:00	1	shop



	Accommon to the second				
user_id	dt		feature_1	feature_n	
777	2020-12-07 00:00:00		88.77	29.01	d
			The same of the sa		













Scala





user_id	promo_id	dt	feature_ds1_1	feature_ds1_n	feature_ds2_1	feature_ds2_n
777	AFP99BC	2020-12-07	88.77	29.01	1	shop



! FEATURES







- Меньше времени на пайплайны (мы не DE)
- Меньше повторений чужой работы
- Данные для исследований != прод
- <u>Согласованность</u> данных (consistency)

?

• Хранить и делиться данными (в real-time)

• Поставлять данные в большом кол-во инструментов (готов работать со всеми ML инструментами)

 Ускорить работу (устранить DE задачи)

• Сделать БД, которая не будет восприниматься, как БД

- Michelangelo (Uber): InfoQ Talk 2019
- Hopsworks (Logical Clocks): Bay Area Al Talk 2019
- Feast (GoJek): HasGeek TV Talk 2019
- Zipline (AirBnB): Spark/Al Summit 2019
- Metaflow (Netflix): MLOps 2019
- FBLearner (Facebook): TWiML Interview 2018
- Feature Factory (Databricks): Spark/Al Summit 2019
- Online Feature Store (Zomato): HasGeek TV Talk 2019
- Galaxy (PInterest): Slides from 2019
- SurveyMonkey Feature Store: Slides from 2020
- Comcast Feature Store: Spark Summit 2018
- Wix Feature Store: Wix Engineering Talk 2019
- Twitter Feature Store: MLOps 2019

- Michelangelo (Uber): InfoQ Talk 2019
- Hopsworks (Logical Clocks): Bay Area Al Talk 2019
- Feast (GoJek): HasGeek TV Talk 2019
- Zipline (AirBnB): Spark/Al Summit 2019
- Metaflow (Netflix): MLOps 2019
- FBLearner (Facebook): TWiML Interview 2018
- Feature Factory (Databricks): Spark/Al Summit 2019
- Online Feature Store (Zomato): HasGeek TV Talk 2019
- Galaxy (PInterest): Slides from 2019
- SurveyMonkey Feature Store: Slides from 2020
- Comcast Feature Store: Spark Summit 2018
- Wix Feature Store: Wix Engineering Talk 2019
- Twitter Feature Store: MLOps 2019

```
# Создать драйвер и зарегистрировать фичи
fs = FeatureSet("all_users_agg_m")
fs.infer_fields_from_df(df)
client.apply(fs)

# загрузить данные в FeatureStore
client.ingest(fs, df)
```

```
        user_id
        dt
        feature_1
        feature_n

        777
        2020-12-07 00:00:00
        88.77
        29.01
```

```
name: all_users_aggr_m
entities:
```

- name: user_id

- valueType: INT32

features:

- name: dt

valueType TIMESTAMP

• • •

```
# Создать драйвер и зарегистрировать фичи
fs = FeatureSet("all_users_agg_m")
fs.infer_fields_from_df(df)
client.apply(fs)

# загрузить данные в FeatureStore
client.ingest(fs, df)
```

user_id	dt	feature_1	feature_n
777	2020-12-07 00:00:00	88.77	29.01

Entity

- Organization ID Type
- User ID
- Ng
- Hash

Feature

• Все остальное

user_id	feature_1	
777	88.77	

```
name: all_users_aggr_m
entities:
    - name: user_id
    - valueType: INT32
features:
    - name: dt
    - valueType TIMESTAMP
...
```

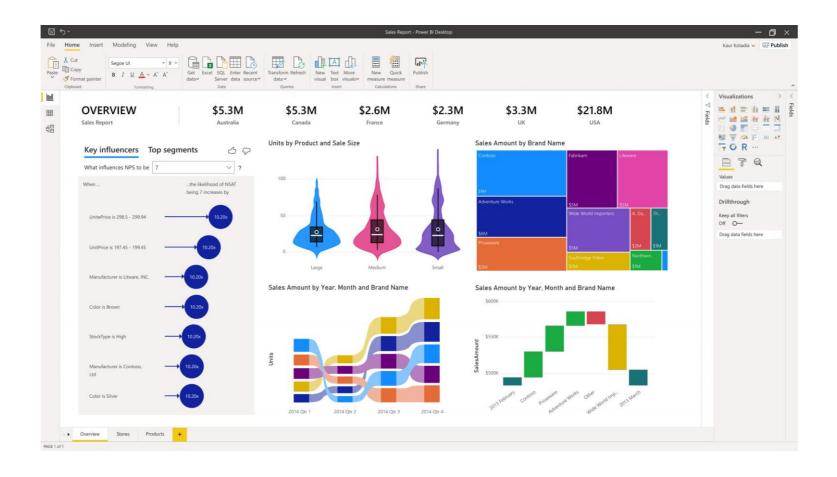
user_id	feature_1	
777	88.77	

FS != DWH

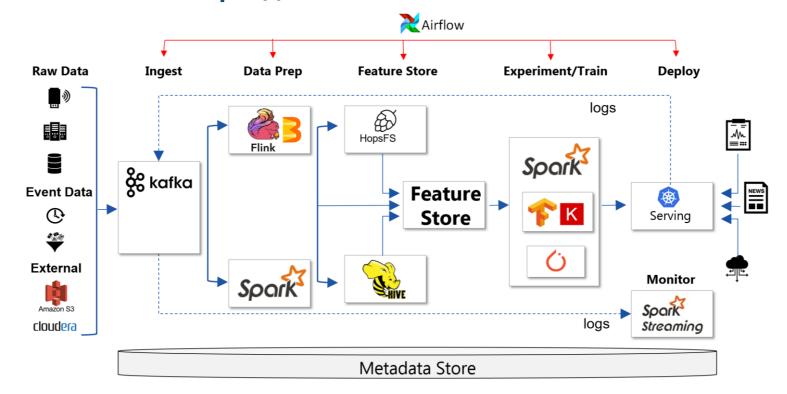


FS != DWH

DS данные – это инсайты поведения, а не статистика для Ві



- DS данные это инсайты поведения, а не статистика для Ві
- Offline / online разделение в базе



- DS данные это инсайты поведения, а не статистика для Ві
- Offline / online разделение в базе
- Включены валидаторы данных (Great Expectations / Deequ)

- DS данные это инсайты поведения, а не статистика для Ві
- Offline / online разделение в базе
- Включены валидаторы данных (Great Expectations / Deequ)
- Фиксация времени и изменений в данных

Параметр	DWH	FS		
Данные	Реляционные схемы	Типизированные данные, зависимость от модели		
МетаДанные	Стандартное мета-хранилище для поиска и обслуживания	DWH + статистики и дрифты		
Пользователи	ВІ	DS		
Порядок доступа	Скрипт запросы	Фильтры, цикличное обращение, ключ к фичам		
Валидация данных	-	GE (python) / D (Scala)		
API	SQL	Python, Scala, Java		

Параметр	DWH	FS		
Данные	Реляционные схемы	Типизированные данные, зависимость от модели		
МетаДанные	Стандартное мета-хранилище для поиска и обслуживания	DWH + статистики и дрифты		
Пользователи	ВІ	DS		
Порядок доступа	Скрипт запросы	Фильтры, цикличное обращение, ключ к фичам		
Валидация данных	-	GE (python) / D (Scala)		
API	SQL	Python, Scala, Java		

СДЕЛАЕМ ВЫБОР



Platform	Open Source	Offline	Online	Metadata	
Hopsworks	AGPL- V3	Hudi/Hive	MySQL Cluster	DB Tables, Elasticsearch	
Michelangelo	n/a	Hive	Cassandra	KV Entries	
Feast	Apache V2	BigQuery	BigTable/Redis	DB Tables	

	Platform	Open Source	Offline	Online	Metadata
	Hopsworks	AGPL- V3	Hudi/Hive	MySQL Cluster	DB Tables, Elasticsearch
سد	Michelangelo	n/a	Hive	Cassandra	KV Entries
	Feast	Apache V2	BigQuery	BigTable/Redis	DB Tables

	Platform	Open Source	Offline	Online	Metadata
https://github.com/logicalclocks/hopsworks	Hopsworks	AGPL- V3	Hudi/Hive	MySQL Cluster	DB Tables, Elasticsearch
	Michelangelo	n/a	Hive	Cassandra	KV Entries
https://github.com/feast-dev/feast	Feast	Apache V2	BigQuery	BigTable/Redis	DB Tables

Platform Online Metadata DB Tables, AGPL-Hudi/Hive https://github.com/logicalclocks/hopsworks Hopsworks MySQL Cluster Elasticsearch **KV Entries** Hive Michelangelo n/a Cassandra https://github.com/feast-dev/feast Feast BigQuery BigTable/Redis **DB Tables**





https://www.youtube.com/watch?v=UNailXoiIrY

https://github.com/ComcastSamples/OSCON-2019-End-to-end-ML-feature-streaming-with-Kubeflow-Kafka-and-Redis-demo-code

КАК РАБОТАЕТ?



ЗАДАНИЕ



ЗАВЕРШИТЬ ЗАДАНИЯ 1, 2, 3

• Сделайте выбор между Feast / HopsWorks